一页结论：被动元件财报问答知识库

一、项目做了什么

用 15 家被动元件上市公司（风华高科、顺络电子、三环集团、法拉电子、火炬电子等）的 2025 年年度报告，建了一个能提问、答案带出处的问答知识库。

技术路线：

1. 从东方财富下载 15 份 2025 年报 PDF。
2. 用 PyMuPDF 提取正文和表格，保留页码标记。
3. 切块（每块约 600 字、不跨页；长段落留 100 字重叠；表格整表保留），每块带公司、章节、页码标签，共 7,470 块。
4. 建两套索引：本地向量（Qwen3-Embedding-0.6B）+ BM25。
5. 做问答页面：双路检索召回，DeepSeek 生成答案，标注出处。

二、测试结果

出了 10 道题，覆盖三类：单公司数据题（4 道）、单公司文字题（3 道）、跨公司全景题（3 道）。

题号	类型	结果
1	单公司数据	✅ 对
2	单公司数据	✅ 对
3	单公司数据	✅ 对
4	单公司数据	✅ 对
5	单公司文字	❌ 错（未找到）
6	单公司文字	✅ 对
7	单公司文字	⚠️ 部分对（不完整）
8	跨公司全景	❌ 错（只找到 2 家）
9	跨公司全景	⚠️ 部分对（只找到 6 家）
10	跨公司全景	❌ 错（只找到 1 家）

三、哪类题答得好、哪类翻车、为什么

答得好的：单公司数据题（4/4 全对）

- 原因：答案集中在少数几个块里（比如“营业收入”就在年报第 18、71、172 页），向量 + BM25 能精准召回。
- 亮点：模型还会做交叉验证（三处数字一致），并主动识别“口径差异”（比如第 219 页是联营企业数据，不是合并口径）。

翻车的：跨公司全景题（0/3 全对）

- 原因：这类题需要“遍历全库汇总”（比如“哪家营收最高”），但向量 + BM25 每次只召回 top-k 个块，不可能召回 15 家公司的所有数据。
- 结果：只能找到 2 家、6 家、1 家，无法完成全量比较。
- 但模型没有编造，数据不够就说“材料未找到”。

翻车的：单公司文字题（1 错、1 部分对）

- 原因：文字型信息（使命/愿景、风险）在年报里散落在多个块里，检索时没有命中。
- 结果：说“未找到”，或只找到部分。
- 但模型没有编造。

四、结论

纯向量 + BM25 的 RAG，适合“单公司、数据型、答案集中”的问题，不适合“跨公司、文字型、答案散落”的问题。

- **跨公司全景题**：需要“遍历全库汇总”，检索式 RAG 做不到，需要**知识图谱**。
- **文字型散落信息**：需要“把散落信息串起来”，检索式 RAG 容易漏，需要**知识图谱**或**调整切块策略**。

下一步方向：如果要继续提升，应该建知识图谱，把 15 家公司的实体、关系、指标织成一张网，支持“跨公司汇总”和“散落信息串联”两类问题。